

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

Khoa đào tạo sau đại học

-----□□□□-----



BÁO CÁO BÀI TẬP LỚN

MÔN HỌC: KHAI PHÁ DỮ LIỆU

CHỦ ĐỀ: SO SÁNH CÁC THUẬT TOÁN HỌC MÁY TRONG PHÂN LOẠI HÌNH ẢNH CHÁY

DỰA TRÊN ĐẶC TRƯNG HOG VÀ COLOR HISTOGRAM

GV Hướng Dẫn: TS. Đỗ Thanh Hà

STT	Họ và tên	Mã học viên	Vai trò
1	Trần Đình Dũng	B25CHHT089	Nhóm trưởng
2	Phạm Minh Hiếu	B25CHHT095	Thành viên
3	Nguyễn Quốc Việt	B25CHHT121	Thành viên

PHÂN CÔNG NHIỆM VỤ

STT	Họ và tên	Vai trò đảm nhiệm	Chi tiết công việc thực hiện
1	Trần Đình Dũng	Trưởng nhóm / Technical Lead & Model Engineering	- Định hướng phương pháp luận, thiết kế kiến trúc hệ thống và pipeline dữ liệu. - Lập trình module trích xuất đặc trưng HOG, Color Histogram và hệ thống Feature Cache (.npy). - Xây dựng, huấn luyện và tối ưu hóa 4 mô hình: Logistic Regression, KNN, SVM và Random Forest. - Phụ trách đánh giá chuyên sâu: 5-Fold Cross-Validation, kiểm định McNemar, PCA và ROC-AUC. - Quản lý và phát triển toàn bộ mã nguồn trong thư mục `src/`.
2	Phạm Minh Hiếu	Data Engineering & Error Analysis	- Thu thập, tiền xử lý, kiểm tra chất lượng và thống kê tập dữ liệu ảnh gốc (`data/raw`). - Phân tích chi tiết các mẫu bị phân loại sai (False Positives và False Negatives). - Trực quan hóa dữ liệu, vẽ biểu đồ Confusion Matrix và so sánh các bộ đặc trưng. - Tham gia đóng góp và hoàn thiện tài liệu báo cáo thực nghiệm của đề tài.
3	Nguyễn Quốc Việt	Model Validation & Documentation	- Phụ trách kiểm thử độc lập, chạy lại pipeline thực nghiệm trên môi trường local. - Thống kê, tổng hợp các bảng chỉ số hiệu năng: Accuracy, Precision, Recall, F1 và AUC. - Biên soạn tài liệu kỹ thuật, hướng dẫn cài đặt, cấu hình môi trường và tái hiện kết quả. - Tổng hợp, chuẩn bị tài liệu và slide báo cáo trình bày đề tài.

Mục lục

CHƯƠNG 1. MỞ ĐẦU	3
1.1. Bối cảnh và tính cấp thiết của đề tài	3
1.2. Phát biểu bài toán	3
1.3. Mục tiêu và câu hỏi nghiên cứu	4
1.4. Đối tượng, phạm vi và giả định nghiên cứu	4
1.5. Phương pháp tiếp cận	5
1.6. Đóng góp của đề tài	6
1.7. Cấu trúc báo cáo	6
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ PHƯƠNG PHÁP	7
2.1. Tổng quan phân loại ảnh bằng học máy truyền thống	7
2.2. Tập dữ liệu và tiền xử lý ảnh	7
2.3. Đặc trưng HOG	8
2.4. Color Histogram trong không gian HSV	8
2.5. Kết hợp đặc trưng và chuẩn hóa dữ liệu	9
2.6. Các thuật toán phân loại	10
2.6.1. Logistic Regression	10
2.6.2. K-Nearest Neighbors	10
2.6.3. Support Vector Machine với kernel RBF	10
2.6.4. Random Forest	10
2.7. Chỉ số đánh giá	11
2.8. Thiết kế đánh giá và kiểm soát rò rỉ dữ liệu	11
2.9. Các kỹ thuật phân tích nâng cao	12
2.9.1. Kiểm định McNemar	12
2.9.2. Principal Component Analysis	12
2.9.3. Phân tích lỗi	12
2.10. Công cụ và tổ chức mã nguồn	13
CHƯƠNG 3. THỰC NGHIỆM VÀ KẾT QUẢ	14
3.1. Mục tiêu và kịch bản thực nghiệm	14
3.2. Kết quả Hold-out trên tập TEST	14
3.3. Phân tích ma trận nhầm lẫn	15
3.4. Kết quả 5-Fold Stratified Cross-Validation	17
3.5. So sánh các bộ đặc trưng	19
3.6. ROC-AUC và khả năng phân biệt hai lớp	20
3.7. Kiểm định McNemar	21
3.8. Phân tích PCA	22
3.9. Khả năng tái lập thực nghiệm	23
CHƯƠNG 4. PHÂN TÍCH VÀ ĐÁNH GIÁ	24
4.1. So sánh tổng thể các mô hình	24

4.2. Độ ổn định và khả năng tổng quát hóa	24
4.3. Vai trò hỗ trợ của HOG và Color Histogram	25
4.4. Đánh đổi giữa hiệu năng và chi phí tính toán	25
4.5. Phân tích lỗi	26
4.5.1. False Positive – báo cháy giả	26
4.5.2. False Negative – bỏ sót cháy	26
4.6. Khuyến nghị lựa chọn mô hình	27
4.7. Hạn chế và các nguy cơ đối với tính hợp lệ	28
4.8. Hướng cải tiến	28
4.8.1. Cải tiến dữ liệu	28
4.8.2. Cải tiến đặc trưng và mô hình	29
4.8.3. Cải tiến đánh giá và triển khai	29
CHƯƠNG 5. KẾT LUẬN	30
5.1. Kết quả đạt được	30
5.2. Trả lời câu hỏi nghiên cứu	30
5.3. Kết luận lựa chọn mô hình	30
5.4. Hướng phát triển tiếp theo	31
TÀI LIỆU THAM KHẢO	32
PHỤ LỤC A. CẤU TRÚC PROJECT VÀ TỆP KẾT QUẢ	34
PHỤ LỤC B. HƯỚNG DẪN CHẠY LẠI THỰC NGHIỆM	35
B.1. Cài đặt môi trường	35
PHỤ LỤC C. MÃ GIẢI QUYẾT TRÌNH XỬ LÝ	36
C.1. Tiền xử lý và trích xuất đặc trưng	36
C.2. Huấn luyện và đánh giá Hold-out	36
C.3. Cross-Validation đúng cách	36
PHỤ LỤC D. KIỂM TRA TÍNH NHẤT QUÁN SỐ LIỆU	37

LỜI MỞ ĐẦU

Cháy rừng và cháy ngoài trời gây thiệt hại lớn về môi trường, tài sản và an toàn con người. Trong các hệ thống giám sát, việc nhận biết sớm dấu hiệu cháy từ ảnh có thể hỗ trợ con người sàng lọc một lượng lớn dữ liệu quan sát. Tuy nhiên, ảnh cháy có sự biến thiên mạnh về kích thước ngọn lửa, điều kiện chiếu sáng, góc chụp, khói che phủ và bối cảnh nền; vì vậy, bài toán phân loại không thể chỉ dựa vào một dấu hiệu đơn lẻ.

Bài tập lớn này khảo sát một hướng tiếp cận học máy truyền thống, trong đó ảnh được chuẩn hóa, trích xuất HOG để mô tả hình dạng và Color Histogram trong không gian HSV để mô tả màu sắc, sau đó đưa vào bốn bộ phân loại Logistic Regression, K-Nearest Neighbors, SVM kernel RBF và Random Forest. Báo cáo tập trung không chỉ vào độ chính xác mà còn đánh giá recall của lớp cháy, specificity, F1-Score, ROC-AUC, thời gian huấn luyện/dự đoán, độ ổn định qua 5-fold cross-validation, kiểm định McNemar và phân tích lỗi.

Nhóm xin trân trọng cảm ơn giảng viên đã cung cấp kiến thức nền tảng và định hướng thực hiện bài tập. Do phạm vi của một bài tập lớn, kết quả hiện tại mới phản ánh tập dữ liệu được cung cấp và chưa thay thế cho một hệ thống cảnh báo cháy đã được kiểm định trong thực địa.

TÓM TẮT

Đề tài xây dựng và đánh giá quy trình phân loại nhị phân ảnh cháy (fire) và không cháy (non_fire) bằng học máy truyền thống. Tập dữ liệu gồm 21.731 ảnh thật, được chia độc lập thành 15.609 ảnh TRAIN và 6.122 ảnh TEST. Mỗi ảnh được đưa về kích thước 128×128 pixel, lọc nhiễu bằng GaussianBlur 3×3 , sau đó trích xuất hai nhóm đặc trưng: HOG 1.764 chiều và Color Histogram HSV 4.096 chiều. Vector Combined có 5.860 chiều được dùng để so sánh Logistic Regression, KNN, SVM RBF và Random Forest trong cùng một quy trình StandardScaler + bộ phân loại.

Trên tập TEST, SVM RBF đạt Accuracy 96,64%, Precision 96,45%, Recall 95,80%, F1-Score 96,12% và ROC-AUC 0,9929, là mô hình có chất lượng dự đoán tổng thể cao nhất. Random Forest bám sát với Accuracy 96,52%, Recall 95,87%, F1-Score 96,00% và AUC 0,9924, trong khi thời gian dự đoán chỉ 0,27 giây so với 275,63 giây của SVM. Kiểm định McNemar cho p-value = 0,6838, chưa cho thấy khác biệt có ý nghĩa thống kê giữa hai mô hình. Cross-validation 5 fold xác nhận Accuracy trung bình của SVM và Random Forest lần lượt là 96,25% và 96,21%.

Thực nghiệm đặc trưng cho thấy Color Histogram đơn tốt hơn HOG đơn, nhưng kết hợp hai nhóm đặc trưng giúp F1-Score tăng lên 96,12%, cao hơn HOG 2,36 điểm phần trăm và cao hơn Color Histogram 1,65 điểm phần trăm. Từ góc độ triển khai, báo cáo khuyến nghị Random Forest khi cần suy luận nhanh và SVM khi ưu tiên tối đa chất lượng dự đoán ngoại tuyến. Kết quả cũng chỉ ra nhu cầu kiểm tra dữ liệu ngoại cảnh, ảnh gần trùng, hiệu chỉnh xác suất và tối ưu ngưỡng để giảm bỏ sót cháy.

Từ khóa: *phân loại ảnh cháy; HOG; Color Histogram; HSV; SVM; Random Forest; khai phá dữ liệu.*

DANH MỤC TỪ VIẾT TẮT

Viết tắt	Diễn giải
AUC	Area Under the Curve – diện tích dưới đường cong ROC
CV	Cross-Validation – đánh giá chéo
FN	False Negative – ảnh cháy bị dự đoán thành không cháy
FP	False Positive – ảnh không cháy bị dự đoán thành cháy
HOG	Histogram of Oriented Gradients
HSV	Hue – Saturation – Value
KNN	K-Nearest Neighbors
LR	Logistic Regression
PCA	Principal Component Analysis
RBF	Radial Basis Function
RF	Random Forest
ROC	Receiver Operating Characteristic
SVM	Support Vector Machine
TN	True Negative – ảnh không cháy được dự đoán đúng
TP	True Positive – ảnh cháy được dự đoán đúng

DANH MỤC BẢNG

Bảng	Trang
Bảng 1.1. Câu hỏi nghiên cứu và tiêu chí trả lời	4
Bảng 2.1. Cấu trúc và phân bố tập dữ liệu	7
Bảng 2.2. Cấu hình tiền xử lý ảnh	8
Bảng 2.3. Cấu hình các bộ đặc trưng	9
Bảng 2.4. Cấu hình bốn mô hình phân loại	10
Bảng 2.5. Các chỉ số đánh giá trong bài toán nhị phân	11
Bảng 2.6. Công cụ và phiên bản thư viện	13
Bảng 3.1. Ma trận kịch bản thực nghiệm	14
Bảng 3.2. Kết quả Hold-out trên tập TEST với đặc trưng Combined	14
Bảng 3.3. Số lượng dự đoán đúng và sai của bốn mô hình	15
Bảng 3.4. Kết quả 5-Fold Stratified Cross-Validation trên TRAIN	17
Bảng 3.5. Chênh lệch giữa Hold-out và trung bình Cross-Validation	18
Bảng 3.6. So sánh ba bộ đặc trưng bằng SVM RBF	19
Bảng 3.7. Chỉ số ROC-AUC của bốn mô hình	20
Bảng 3.8. Bảng chéo và kết quả kiểm định McNemar	21
Bảng 3.9. Tỷ lệ phương sai được giải thích bởi PCA 2D	22
Bảng 4.1. Đánh đổi hiệu năng và chi phí tính toán giữa SVM và Random Forest	26
Bảng 4.2. Tổng hợp nguyên nhân các trường hợp phân loại sai	26
Bảng 4.3. Hạn chế của nghiên cứu và hướng khắc phục	28
Bảng 5.1. Đối chiếu mục tiêu nghiên cứu và kết quả đạt được	30
Bảng A.1. Cấu trúc thư mục chính của project	34
Bảng A.2. Danh sách tệp kết quả chính thức	34
Bảng B.1. Trình tự chạy lại các bước thực nghiệm	35
Bảng D.1. Đối soát chỉ số từ ma trận nhầm lẫn	37

DANH MỤC HÌNH

Tên hình	Trang
Hình 3.1. So sánh các chỉ số Hold-out của bốn mô hình	15
Hình 3.2. Ma trận nhầm lẫn của bốn mô hình trên tập TEST	17
Hình 3.3. F1-Score qua 5-Fold Cross-Validation	18
Hình 3.4. So sánh F1-Score của ba bộ đặc trưng	19
Hình 3.5. So sánh thời gian huấn luyện và dự đoán	20
Hình 3.6. Đường cong ROC của bốn mô hình	21
Hình 3.7. Phân bố dữ liệu trong không gian PCA hai chiều	22
Hình 4.1. Một số trường hợp False Positive và False Negative của SVM và Random Forest	27

CHƯƠNG 1. MỞ ĐẦU

1.1. Bối cảnh và tính cấp thiết của đề tài

Phát hiện sớm cháy từ camera giám sát hoặc ảnh hiện trường là một bài toán có giá trị thực tiễn cao. Một hệ thống phân loại ảnh có thể đóng vai trò bộ lọc ban đầu, ưu tiên các khung hình nghi ngờ để con người kiểm tra. Khác với bài toán nhận dạng vật thể trong môi trường kiểm soát, dấu hiệu cháy biến đổi mạnh: ngọn lửa có thể rất nhỏ hoặc chiếm gần toàn ảnh; màu lửa thay đổi theo nhiên liệu và độ phơi sáng; khói có thể che khuất; nền ảnh có thể chứa mặt trời, ánh đèn, lá đỏ hoặc bầu trời hoàng hôn có màu gần giống lửa.

Deep Learning hiện là hướng phổ biến cho phân loại ảnh, nhưng yêu cầu tài nguyên tính toán, quy mô dữ liệu và quy trình tối ưu tương đối lớn. Trong phạm vi môn Khai phá dữ liệu, đề tài lựa chọn cách tiếp cận học máy truyền thống nhằm làm rõ toàn bộ chuỗi xử lý từ dữ liệu thô, trích xuất đặc trưng, chuẩn hóa, huấn luyện, đánh giá đến kiểm định thống kê. Hướng tiếp cận này giúp quan sát trực tiếp vai trò của đặc trưng hình dạng và màu sắc, đồng thời tạo ra baseline có khả năng giải thích và tái lập.

Trọng tâm: Đề tài không xây dựng hệ thống cảnh báo cháy hoàn chỉnh; mục tiêu là so sánh công bằng bốn mô hình học máy trên cùng tập dữ liệu, cùng vector đặc trưng và cùng quy trình đánh giá.

1.2. Phát biểu bài toán

Với một ảnh đầu vào x , mô hình cần dự đoán nhãn $y \in \{0, 1\}$, trong đó $y = 1$ biểu diễn lớp fire và $y = 0$ biểu diễn lớp non_fire. Đây là bài toán học có giám sát với hai lớp. Mô hình được học từ tập TRAIN có nhãn, sau đó được đánh giá một lần trên tập TEST độc lập để ước lượng hiệu năng trên dữ liệu chưa quan sát.

$$f: \mathbb{R}^{5860} \rightarrow \{0, 1\}$$

Đầu vào của bộ phân loại là vector Combined gồm 5.860 đặc trưng HOG và HSV Histogram.

Do mục tiêu ứng dụng liên quan đến cháy, lỗi bỏ sót ảnh cháy (False Negative) có ý nghĩa vận hành nghiêm trọng hơn một lỗi báo cháy giả trong nhiều bối cảnh. Vì vậy, Accuracy không được sử dụng đơn độc; báo cáo đồng thời phân tích Recall của lớp fire, F1-Score, Specificity, ROC-AUC và toàn bộ ma trận nhầm lẫn.

1.3. Mục tiêu và câu hỏi nghiên cứu

Đề tài đặt ra các mục tiêu cụ thể sau:

- Xây dựng quy trình tiền xử lý và trích xuất đặc trưng nhất quán cho toàn bộ ảnh.
- So sánh bốn thuật toán học máy truyền thống trên cùng bộ đặc trưng Combined.
- Đánh giá mức độ hỗ trợ giữa HOG và Color Histogram.
- Kiểm tra độ ổn định qua 5-Fold Stratified Cross-Validation và tập TEST độc lập.
- Phân tích ý nghĩa thống kê, chi phí tính toán và các dạng lỗi điển hình.
- Đề xuất mô hình phù hợp cho bối cảnh triển khai thực tế.

Bảng 1.1. Câu hỏi nghiên cứu và tiêu chí trả lời

Mã	Câu hỏi nghiên cứu	Bảng chứng sử dụng
RQ1	Mô hình nào có chất lượng phân loại tốt nhất?	Accuracy, F1, Recall, Specificity và AUC trên TEST.
RQ2	HOG và Color Histogram đóng góp như thế nào?	So sánh HOG, Color Histogram và Combined bằng SVM RBF.
RQ3	Kết quả có ổn định trên các phân hoạch dữ liệu không?	Mean $\pm$ Std của 5-fold CV và độ lệch với Hold-out.
RQ4	SVM và Random Forest có khác biệt có ý nghĩa thống kê không?	Kiểm định McNemar trên cùng 6.122 dự đoán TEST.
RQ5	Mô hình nào phù hợp để triển khai?	Đánh đổi chất lượng, Recall, thời gian huấn luyện và dự đoán.

Nguồn: Nhóm thực hiện, tổng hợp từ dữ liệu thực nghiệm chính thức.

1.4. Đối tượng, phạm vi và giả định nghiên cứu

Đối tượng nghiên cứu gồm:

- Tập ảnh hai lớp fire và non_fire đã được chia sẵn thành TRAIN và TEST.
- Hai bộ mô tả đặc trưng thủ công: HOG và Color Histogram HSV.

- Bốn thuật toán: Logistic Regression, KNN, SVM RBF và Random Forest.
- Các quy trình đánh giá: Hold-out, 5-fold CV, ROC-AUC, McNemar, PCA và phân tích lỗi.

Phạm vi đề tài không bao gồm phát hiện vị trí ngọn lửa trong ảnh, xử lý video theo thời gian thực, Deep Learning, học tăng cường hoặc tích hợp cảm biến nhiệt/khói. Các kết luận được hiểu trong phạm vi tập dữ liệu hiện có. Báo cáo giả định việc chia TRAIN/TEST được thực hiện độc lập trước khi nhóm huấn luyện mô hình và tập TEST không được dùng để fit StandardScaler hoặc mô hình.

Giới hạn nguồn dữ liệu: Tập kỹ thuật được cung cấp nêu tên “Forest Fire & Non-Fire Dataset” nhưng chưa có đường dẫn hoặc giấy phép nguồn. Vì vậy báo cáo không tự gán một nguồn công khai cụ thể và coi đây là khoảng trống cần bổ sung trước khi nộp bản cuối cùng.

1.5. Phương pháp tiếp cận

Quy trình nghiên cứu bắt đầu từ ảnh thô đã chia tập. Ảnh được chuẩn hóa về kích thước, lọc nhiễu, sau đó trích xuất HOG và histogram màu HSV. Các vector được lưu cache dưới dạng NumPy float32 để không lặp lại bước trích xuất trong từng thí nghiệm. Trong mỗi pipeline, StandardScaler được fit trên dữ liệu huấn luyện tương ứng, rồi mới biến đổi dữ liệu validation hoặc TEST. Sau khi huấn luyện, mô hình được đánh giá ở cả góc độ hiệu năng dự đoán, độ ổn định, thời gian và ý nghĩa thống kê.

1.6. Đóng góp của đề tài

Các đóng góp chính của bài tập lớn gồm:

1. Xây dựng pipeline hoàn chỉnh, tái sử dụng được, không fit scaler trên TEST.
2. Thiết lập baseline bằng bốn thuật toán đại diện cho mô hình tuyến tính, dựa trên lân cận, kernel và tổ hợp cây.
3. Thực hiện so sánh đặc trưng để định lượng giá trị hỗ trợ giữa hình dạng và màu sắc.
4. Bổ sung phân tích ROC-AUC, McNemar, PCA, ma trận nhầm lẫn và mẫu lỗi thay vì chỉ báo cáo Accuracy.
5. Đưa ra khuyến nghị triển khai dựa trên cả chất lượng và độ trễ suy luận.

1.7. Cấu trúc báo cáo

Ngoài phần mở đầu, Chương 2 trình bày cơ sở lý thuyết và phương pháp; Chương 3 mô tả thiết kế thực nghiệm cùng toàn bộ số liệu kết quả; Chương 4 phân tích, đánh giá, nhận diện hạn chế và đề xuất hướng cải tiến; Chương 5 tổng kết các kết quả chính và trả lời câu hỏi nghiên cứu. Phần cuối gồm tài liệu tham khảo và các phụ lục phục vụ tái lập.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ PHƯƠNG PHÁP

2.1. Tổng quan phân loại ảnh bằng học máy truyền thống

Trong học máy truyền thống, ảnh không được đưa trực tiếp vào bộ phân loại ở dạng ma trận pixel thô. Một hàm trích xuất đặc trưng biến ảnh thành vector có kích thước cố định, trong đó mỗi nhóm giá trị mô tả một khía cạnh có ý nghĩa: cạnh, hướng gradient, màu sắc hoặc kết cấu. Bộ phân loại sau đó học ranh giới quyết định trong không gian đặc trưng [1]. Hiệu quả của hệ thống phụ thuộc đồng thời vào khả năng biểu diễn của đặc trưng và giả định của mô hình.

Đề tài chọn HOG để mô tả cấu trúc biên và Color Histogram để mô tả phân bố màu. Hai nhóm tín hiệu này phù hợp trực giác của bài toán: lửa thường có biên không đều, hướng bốc lên và vùng màu nóng sáng. Việc kết hợp giúp giảm rủi ro khi một loại tín hiệu bị nhiễu, chẳng hạn cảnh hoàng hôn có màu giống lửa nhưng không có cấu trúc biên tương ứng.

2.2. Tập dữ liệu và tiền xử lý ảnh

Bảng 2.1. Cấu trúc và phân bố tập dữ liệu

Tập	Tổng ảnh	fire	non_fire	Tỉ lệ fire / non_fire
TRAIN	15.609	7.804	7.805	50,00% / 50,00%
TEST	6.122	2.665	3.457	43,53% / 56,47%
Tổng	21.731	10.469	11.262	48,18% / 51,82%

Nguồn: Tập context kỹ thuật và số liệu thực nghiệm chính thức do nhóm cung cấp.

Tập TRAIN chiếm 71,83% toàn bộ dữ liệu và cân bằng gần như tuyệt đối giữa hai lớp. Tập TEST chiếm 28,17% và có tỉ lệ non_fire cao hơn. Sự khác biệt phân bố này là lý do cần quan sát thêm Recall, Specificity và F1-Score thay vì chỉ dựa vào Accuracy.

Bảng 2.2. Cấu hình tiền xử lý ảnh

Bước	Cấu hình	Công cụ	Mục đích
Resize	128×128 pixel	cv2.INTER_AREA	Chuẩn hóa kích thước; phù hợp khi thu nhỏ ảnh.
Lọc nhiễu	GaussianBlur 3×3	Gaussian kernel	Giảm nhiễu tần số cao nhưng vẫn giữ biên chính.
Chuyển màu	BGR $\rightarrow$ HSV	cv2.cvtColor	Tách Hue khỏi độ bão hòa và độ sáng [8].
Kiểu dữ liệu đặc trưng	float32	NumPy .npy	Giảm dung lượng cache và tăng tốc nạp.

Resize tạo ra đầu vào đồng nhất cho HOG; GaussianBlur nhẹ hạn chế các cạnh giả do nhiễu nhưng không làm mất hoàn toàn cấu trúc ngọn lửa. Tất cả thao tác được áp dụng độc lập trên từng ảnh, không sử dụng thống kê toàn tập nên không gây rò rỉ nhãn.

2.3. Đặc trưng HOG

Histogram of Oriented Gradients biểu diễn ảnh thông qua phân bố hướng gradient cục bộ. Phương pháp chia ảnh thành các cell, tính hướng và độ lớn gradient, gom phiếu vào histogram theo hướng, sau đó chuẩn hóa các cell lân cận trong block để giảm tác động của độ sáng và độ tương phản [2], [7]. Trong đề tài, ảnh xám 128×128 được chia thành cell 16×16 ; mỗi block gồm 2×2 cell và có 9 hướng.

$$\text{Số cell mỗi chiều} = 128 / 16 = 8; \text{số vị trí block mỗi chiều} = 8 - 2 + 1 = 7$$

$$\text{Số chiều HOG} = 7 \times 7 \times (2 \times 2 \times 9) = 1.764$$

Chuẩn hóa L2-Hys được sử dụng cho mỗi block. Vector HOG nhấn mạnh cấu trúc cạnh và hướng thay vì giá trị màu tuyệt đối. Đối với lửa, đặc trưng này có thể ghi nhận đường biên không đều và cấu trúc bốc lên, nhưng có thể yếu khi ngọn lửa quá nhỏ, bị khói che hoặc ảnh thiếu nét.

2.4. Color Histogram trong không gian HSV

Không gian HSV gồm Hue (sắc màu), Saturation (độ bão hòa) và Value (độ sáng). So với việc quan sát trực tiếp ba kênh RGB/BGR, HSV tách thành phần màu khỏi cường độ sáng tương đối rõ hơn, thuận lợi cho việc mô tả các vùng đỏ, cam và

vàng dưới điều kiện chiếu sáng biến đổi. OpenCV biểu diễn Hue trên miền $[0, 180)$, còn Saturation và Value trên $[0, 256)$ đối với ảnh 8-bit [8].

Đề tài tính histogram ba chiều với 16 bins cho mỗi kênh. Mỗi pixel đóng góp vào một ô H-S-V; histogram sau đó được chuẩn hóa bằng `cv2.normalize` để hạn chế ảnh hưởng của số lượng pixel tuyệt đối.

$$\text{Số chiều Color Histogram} = 16 \times 16 \times 16 = 4.096$$

Color Histogram không lưu vị trí không gian chi tiết. Do đó, nó nhận biết tốt tỷ trọng màu đặc trưng nhưng có thể nhầm cảnh hoàng hôn, đèn cao áp hoặc tán lá mùa thu với lửa. Đây chính là lý do cần bổ sung HOG.

2.5. Kết hợp đặc trưng và chuẩn hóa dữ liệu

Bảng 2.3. Cấu hình các bộ đặc trưng

Bộ đặc trưng	Số chiều	Cấu hình chính	Thông tin biểu diễn
HOG	1.764	9 hướng; cell 16×16 ; block 2×2 ; L2-Hys	Hình dạng, cạnh, hướng gradient
Color Histogram	4.096	HSV 3D; 16 bins/kênh; chuẩn hóa	Màu sắc, bão hòa, độ sáng
Combined	5.860	Nối HOG và Color Histogram	Thông tin hình dạng + màu sắc

Hai vector được nối theo chiều đặc trưng. Color Histogram chiếm khoảng 69,90% số chiều Combined, còn HOG chiếm 30,10%. Số chiều không đồng nghĩa trực tiếp với mức đóng góp dự đoán; vì thế cần thực nghiệm so sánh đặc trưng ở Chương 3.

StandardScaler chuẩn hóa mỗi đặc trưng về trung bình xấp xỉ 0 và độ lệch chuẩn xấp xỉ 1. Bước này đặc biệt quan trọng đối với KNN, Logistic Regression và SVM vì các mô hình nhạy với thang đo. Scaler được đặt trong `sklearn.pipeline.Pipeline` để bảo đảm mỗi fold chỉ học thống kê từ phần TRAIN tương ứng [6], [13].

$$z_{ij} = (x_{ij} - \mu_{[i], TRAIN}) / \sigma_{[i], TRAIN}$$

Nguyên tắc chống leakage: Không fit StandardScaler trên toàn bộ dữ liệu trước khi cross-validation và không fit trên TEST. Mỗi pipeline fit scaler và mô hình chỉ bằng dữ liệu TRAIN của fold hoặc toàn bộ TRAIN ở kịch bản Hold-out.

2.6. Các thuật toán phân loại

2.6.1. Logistic Regression

Logistic Regression mô hình hóa xác suất lớp fire thông qua hàm sigmoid của tổ hợp tuyến tính các đặc trưng. Đây là baseline có tốc độ huấn luyện và dự đoán tốt, dễ diễn giải, nhưng ranh giới tuyến tính có thể chưa đủ linh hoạt cho không gian HOG + màu có tương tác phi tuyến.

$$P(y = 1 | x) = 1 / (1 + e^{-(w^T x + b)})$$

2.6.2. K-Nearest Neighbors

KNN dự đoán nhãn dựa trên đa số của k mẫu gần nhất theo khoảng cách Euclidean [4]. Với k = 5, mô hình gần như không có chi phí fit nhưng phải tính khoảng cách tới nhiều mẫu khi dự đoán. Trong không gian 5.860 chiều, khoảng cách giữa các điểm có thể kém phân biệt do lời nguyền số chiều.

2.6.3. Support Vector Machine với kernel RBF

SVM tìm siêu phẳng có biên phân cách lớn; kernel RBF ánh xạ ngàm dữ liệu vào không gian phi tuyến và cho phép xây dựng ranh giới mềm dẻo [3]. Tham số C = 10 đặt mức phạt tương đối cao cho lỗi huấn luyện, còn gamma = scale được tính từ số đặc trưng và phương sai dữ liệu. Nhược điểm là thời gian fit và suy luận tăng khi số support vectors lớn.

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$$

2.6.4. Random Forest

Random Forest kết hợp nhiều cây quyết định được huấn luyện trên các mẫu bootstrap và tập con đặc trưng ngẫu nhiên. Bình chọn của 200 cây giúp giảm phương sai so với một cây đơn, xử lý tốt quan hệ phi tuyến và ít phụ thuộc vào thang đo [5]. Trong project, n_jobs = -1 cho phép sử dụng tối đa core CPU.

Bảng 2.4. Cấu hình bốn mô hình phân loại

Mô hình	Siêu tham số chính	Đặc điểm
Logistic Regression	max_iter=1000; class_weight=balanced; random_state=42	Tuyến tính; baseline nhanh
KNN	n_neighbors=5; Euclidean	Không class_weight; fit rất nhanh

Mô hình	Siêu tham số chính	Đặc điểm
SVM RBF	C=10; gamma=scale; class_weight=balanced; cache=1000 MB	Phi tuyến; chi phí cao
Random Forest	n_estimators=200; class_weight=balanced; n_jobs=-1	Tổ hợp cây; suy luận nhanh

Nguồn: Nhóm thực hiện, tổng hợp từ dữ liệu thực nghiệm chính thức.

Tập TRAIN đã cân bằng nên class_weight=balanced gần như không làm thay đổi trọng số lớp trong huấn luyện, nhưng giúp cấu hình nhất quán và an toàn nếu phân bố fold có sai lệch nhỏ. KNN không hỗ trợ class_weight theo cùng cơ chế.

2.7. Chỉ số đánh giá

Ký hiệu TP là ảnh fire dự đoán đúng; TN là ảnh non_fire dự đoán đúng; FP là non_fire bị báo nhầm thành fire; FN là fire bị bỏ sót. Các chỉ số được tính với fire là lớp dương.

Bảng 2.5. Các chỉ số đánh giá trong bài toán nhị phân

Chỉ số	Công thức / định nghĩa	Ý nghĩa
Accuracy	$(TP + TN) / (TP + TN + FP + FN)$	Tỉ lệ dự đoán đúng toàn bộ.
Precision	$TP / (TP + FP)$	Độ tin cậy của cảnh báo fire.
Recall / Sensitivity	$TP / (TP + FN)$	Khả năng phát hiện ảnh fire.
Specificity	$TN / (TN + FP)$	Khả năng loại đúng ảnh non_fire.
F1-Score	$2 \times \text{Precision} \times \text{Recall} / (\text{Precision} + \text{Recall})$	Cân bằng Precision và Recall.
ROC-AUC	Diện tích dưới đường ROC	Khả năng xếp hạng hai lớp trên nhiều ngưỡng.

Nguồn: Nhóm thực hiện, tổng hợp từ dữ liệu thực nghiệm chính thức.

ROC biểu diễn quan hệ giữa True Positive Rate và False Positive Rate khi thay đổi ngưỡng quyết định; AUC càng gần 1, khả năng phân biệt hai lớp càng tốt [10]. Tuy nhiên, AUC không thay thế phân tích tại ngưỡng vận hành cụ thể, đặc biệt khi chi phí FN và FP khác nhau.

2.8. Thiết kế đánh giá và kiểm soát rò rỉ dữ liệu

Đề tài sử dụng hai lớp đánh giá bổ sung cho nhau. Hold-out huấn luyện trên toàn bộ 15.609 mẫu TRAIN và đánh giá trên 6.122 mẫu TEST độc lập. 5-Fold Stratified Cross-Validation chỉ thực hiện trong TRAIN; mỗi fold giữ xấp xỉ cùng tỉ lệ nhãn như

tập gốc [9]. Mỗi mẫu lần lượt làm validation đúng một lần, và kết quả báo cáo dưới dạng trung bình $\pm$ độ lệch chuẩn.

Tập TEST phải được giữ kín cho đến bước đánh giá cuối. Việc lựa chọn hoặc điều chỉnh siêu tham số sau khi xem kết quả TEST sẽ biến TEST thành một phần của quá trình phát triển và làm lạc quan hóa ước lượng hiệu năng. Theo context kỹ thuật, project giữ TEST độc lập; báo cáo coi đây là điều kiện của các kết luận.

Diễn giải đúng về overfitting: Kết quả CV và Hold-out gần nhau là dấu hiệu tích cực về độ ổn định, nhưng không đủ để chứng minh tuyệt đối rằng mô hình “không hề overfitting”. Cần thêm validation ngoài miền, kiểm tra ảnh gần trùng và quy trình chọn siêu tham số độc lập để củng cố kết luận.

2.9. Các kỹ thuật phân tích nâng cao

2.9.1. Kiểm định McNemar

McNemar so sánh hai bộ phân loại trên cùng tập mẫu bằng cách chỉ quan tâm đến các trường hợp hai mô hình bất đồng. Với b là số mẫu mô hình A đúng/B sai và c là A sai/B đúng, thống kê hiệu chỉnh liên tục được tính như sau [11]:

$$\chi^2 = (|b - c| - 1)^2 / (b + c)$$

Giả thuyết không H_0 cho rằng xác suất mắc lỗi của hai mô hình là tương đương. Nếu $p < 0,05$, có thể bác bỏ H_0 ở mức ý nghĩa 5%; ngược lại, chưa đủ bằng chứng để kết luận khác biệt.

2.9.2. Principal Component Analysis

PCA biến đổi tuyến tính dữ liệu sang các trục trực giao lần lượt cực đại hóa phương sai [12]. Project giảm 5.860 chiều xuống PC1 và PC2 để trực quan hóa không gian đặc trưng. Vì hai thành phần chỉ giữ một phần nhỏ tổng phương sai, hình 2D chỉ có giá trị khám phá và không đại diện đầy đủ cho ranh giới phi tuyến của mô hình.

2.9.3. Phân tích lỗi

Phân tích lỗi truy xuất trực tiếp ảnh FP và FN. FP giúp nhận diện những bối cảnh màu sắc hoặc ánh sáng gây nhầm; FN cho biết các trường hợp nguy hiểm như lửa nhỏ, bị khói che hoặc thiếu sáng. Đây là cơ sở để đề xuất cải tiến dữ liệu, đặc trưng và ngưỡng vận hành.

2.10. Công cụ và tổ chức mã nguồn

Bảng 2.6. Công cụ và phiên bản thư viện

Công cụ	Phiên bản	Mục đích
Python	≥ 3.10	Ngôn ngữ và môi trường chạy
scikit-learn	≥ 1.3	Pipeline, mô hình, CV và metrics [6]
scikit-image	≥ 0.21	Trích xuất HOG [7]
opencv-python	≥ 4.8	Đọc ảnh, resize, blur và histogram HSV [8]
NumPy	≥ 1.24	Mảng số và feature cache
pandas	≥ 2.0	Xử lý và xuất kết quả CSV
matplotlib / seaborn	$\geq 3.7 / 0.12$	Trực quan hóa kết quả
SciPy	≥ 1.11	Tính kiểm định thống kê

Nguồn: requirements và mô tả kỹ thuật do nhóm cung cấp.

Mã nguồn được chia theo chức năng: `data_loader.py` đọc dữ liệu; `preprocess.py` chuẩn hóa ảnh; `features.py` trích xuất đặc trưng; `feature_cache.py` tạo cache; các script `train_compare`, `train_cv`, `feature_compare`, `final_evaluation` và `advanced_analysis` thực hiện từng nhóm thí nghiệm. Cách tổ chức này tách rõ dữ liệu, mô hình và báo cáo, thuận lợi cho kiểm thử và tái lập. Mã nguồn và hướng dẫn tái lập được công bố tại repository GitHub của dự án.

CHƯƠNG 3. THỰC NGHIỆM VÀ KẾT QUẢ

3.1. Mục tiêu và kịch bản thực nghiệm

Thực nghiệm được thiết kế để lần lượt trả lời năm câu hỏi nghiên cứu. Mọi mô hình so sánh thuật toán đều sử dụng cùng vector Combined 5.860 chiều. So sánh đặc trưng cố định bộ phân loại SVM RBF để tách ảnh hưởng của biểu diễn đầu vào khỏi ảnh hưởng của thuật toán.

Bảng 3.1. Ma trận kịch bản thực nghiệm

Mã	Mục tiêu	Dữ liệu	Đặc trưng	Mô hình	Đầu ra
E1	So sánh thuật toán	TRAIN → TEST	Combined	LR, KNN, SVM, RF	Metrics, AUC, thời gian
E2	Độ ổn định	5-fold trong TRAIN	Combined	LR, KNN, SVM, RF	Mean ± Std
E3	So sánh đặc trưng	TRAIN → TEST	HOG / Color / Combined	SVM RBF	Metrics, tổng thời gian
E4	So sánh thống kê	Cùng TEST	Combined	SVM vs RF	McNemar
E5	Không gian đặc trưng	TRAIN	Combined	PCA 2D	Explained variance
E6	Phân tích lỗi	TEST	Combined	SVM và RF	FP/FN điển hình

Nguồn: Nhóm thực hiện, tổng hợp từ dữ liệu thực nghiệm chính thức.

Các kết quả dưới đây được xem là số liệu chính thức của project. Dấu phẩy được dùng làm dấu thập phân trong phần trình bày tiếng Việt; thời gian tính bằng giây. Mọi metric lớp đều coi fire là lớp dương.


3.2. Kết quả Hold-out trên tập TEST

Bảng 3.2. Kết quả Hold-out trên tập TEST với đặc trưng Combined

Thuật toán	Accuracy	Precision	Recall	F1	Specificity	AUC
Logistic Regression	94,46%	93,49%	93,81%	93,65%	94,97%	0,9750
KNN (k=5)	88,29%	90,96%	81,16%	85,78%	93,78%	0,9490
SVM (RBF)	96,64%	96,45%	95,80%	96,12%	97,28%	0,9929
Random Forest	96,52%	96,12%	95,87%	96,00%	97,02%	0,9924

Nguồn: Nhóm thực hiện, tổng hợp từ dữ liệu thực nghiệm chính thức.

SVM RBF đứng đầu về Accuracy, Precision, F1-Score, Specificity và AUC. Random Forest đứng đầu Recall với 95,87%, cao hơn SVM 0,07 điểm phần trăm, đồng thời chỉ kém 0,12 điểm phần trăm về Accuracy và 0,12 điểm phần trăm về F1. Logistic Regression đạt baseline tốt nhưng thấp hơn SVM 2,18 điểm phần trăm Accuracy. KNN có Recall 81,16%, cho thấy bỏ sót nhiều ảnh fire.



Hình 3.1. So sánh các chỉ số Hold-out của bốn mô hình

3.3. Phân tích ma trận nhầm lẫn


Bảng 3.3. Số lượng dự đoán đúng và sai của bốn mô hình

Mô hình	TP	TN	FP	FN	Tổng lỗi	Train (s)	Predict (s)
Logistic Regression	2.500	3.283	174	165	339	7,48	0,30
KNN (k=5)	2.163	3.242	215	502	717	1,53	17,86
SVM (RBF)	2.553	3.363	94	112	206	467,15	275,63
Random Forest	2.555	3.354	103	110	213	50,37	0,27


Nguồn: Nhóm thực hiện, tổng hợp từ dữ liệu thực nghiệm chính thức.

SVM dự đoán đúng 5.916/6.122 ảnh và mắc 206 lỗi; Random Forest dự đoán đúng 5.909 ảnh và mắc 213 lỗi. Random Forest có ít FN hơn hai mẫu nhưng nhiều FP hơn chín mẫu so với SVM. Logistic Regression mắc 339 lỗi. KNN mắc 717 lỗi, trong đó 502 là FN; tỉ lệ bỏ sót fire đạt 18,84%, cao hơn đáng kể SVM (4,20%) và Random Forest (4,13%).


Official Confusion Matrix: K-Nearest Neighbors




Official Confusion Matrix: Logistic Regression



Official Confusion Matrix: Random Forest





Hình 3.2. Ma trận nhầm lẫn của bốn mô hình trên tập TEST

Quan sát vận hành: Nếu ưu tiên giảm bỏ sót cháy tại ngưỡng mặc định, Random Forest tốt hơn SVM rất nhẹ về Recall. Nếu ưu tiên giảm báo cháy giả, SVM tốt hơn với 94 FP so với 103 FP.


3.4. Kết quả 5-Fold Stratified Cross-Validation

Bảng 3.4. Kết quả 5-Fold Stratified Cross-Validation trên TRAIN

Thuật toán	Accuracy	Precision	Recall	F1-Score	Thời gian (s)
Logistic Regression	94,50% ± 0,45%	94,77% ± 0,37%	94,21% ± 0,63%	94,49% ± 0,46%	31,23
KNN (k=5)	88,09% ± 0,52%	94,20% ± 0,60%	81,18% ± 0,87%	87,20% ± 0,59%	51,11
SVM (RBF)	96,25% ± 0,53%	97,30% ± 0,53%	95,14% ± 0,60%	96,21% ± 0,54%	2.313,85
Random Forest	96,21% ± 0,37%	96,51% ± 0,61%	95,89% ± 0,53%	96,20% ± 0,37%	213,08

Nguồn: cross_validation_OFFICIAL.csv; số liệu trình bày Mean ± Std.

SVM và Random Forest tiếp tục dẫn đầu với Accuracy trung bình lần lượt 96,25% và 96,21%; độ lệch chuẩn đều dưới 0,55 điểm phần trăm. Random Forest có Recall trung bình cao nhất 95,89%; SVM có Precision cao nhất 97,30%. SVM cần 2.313,85 giây (khoảng 38,56 phút), cao hơn Random Forest khoảng 10,86 lần trong toàn bộ quá trình CV.



Hình 3.3. F1-Score qua 5-Fold Cross-Validation

Bảng 3.5. Chênh lệch giữa Hold-out và trung bình Cross-Validation

Mô hình	Δ Accuracy	Δ F1	Diễn giải
Logistic Regression	-0,04 điểm %	-0,84 điểm %	Accuracy rất gần; F1 trên TEST thấp hơn.
KNN (k=5)	+0,20 điểm %	-1,42 điểm %	Accuracy gần; F1 giảm do Recall fire thấp trên TEST.
SVM (RBF)	+0,39 điểm %	-0,09 điểm %	Hai đánh giá nhất quán.
Random Forest	+0,31 điểm %	-0,20 điểm %	Hai đánh giá nhất quán.

Nguồn: Nhóm thực hiện tính từ Bảng 3.2 và Bảng 3.4; Δ = Hold-out – CV mean.

Độ lệch Accuracy của cả bốn mô hình nằm trong 0,39 điểm phần trăm, cho thấy thứ hạng và hiệu năng tổng thể ổn định. Tuy nhiên, khẳng định “mọi độ lệch đều dưới 0,5%” không đúng nếu áp dụng cho F1: Logistic Regression lệch 0,84 và KNN lệch 1,42 điểm phần trăm. Điều này có thể liên quan đến phân bố lớp TEST khác TRAIN và sự suy giảm Recall của KNN.


3.5. So sánh các bộ đặc trưng

Bảng 3.6. So sánh ba bộ đặc trưng bằng SVM RBF


Đặc trưng	Chiều	Acc.	Prec.	Recall	F1	Spec.	Tổng TG (s)
HOG	1.764	94,58%	93,94%	93,58%	93,76%	95,34%	285,53
Color Histogram	4.096	95,20%	94,79%	94,15%	94,47%	96,01%	680,28
Combined	5.860	96,64%	96,45%	95,80%	96,12%	97,28%	1.083,04

Nguồn: *feature_comparison_OFFICIAL.csv*; tổng thời gian gồm toàn bộ bước trong kịch bản so sánh.

Color Histogram đơn vượt HOG 0,62 điểm phần trăm Accuracy và 0,71 điểm phần trăm F1, cho thấy màu sắc là tín hiệu mạnh trong tập dữ liệu. Combined tiếp tục tăng Accuracy 2,06 điểm phần trăm và F1 2,36 điểm phần trăm so với HOG; tăng Accuracy 1,44 và F1 1,65 điểm phần trăm so với Color Histogram. Đổi lại, số chiều và tổng thời gian xử lý tăng.



Hình 3.4. So sánh F1-Score của ba bộ đặc trưng




Hình 3.5. So sánh thời gian huấn luyện và dự đoán

3.6. ROC-AUC và khả năng phân biệt hai lớp

Bảng 3.7. Chỉ số ROC-AUC của bốn mô hình

Mô hình	Nguồn score	AUC	Nhận xét
Logistic Regression	predict_proba / score	0,9750	Rất tốt
KNN (k=5)	predict_proba	0,9490	Tốt
SVM (RBF)	decision_function	0,9929	Xuất sắc
Random Forest	predict_proba	0,9924	Xuất sắc

Nguồn: Nhóm thực hiện, tổng hợp từ dữ liệu thực nghiệm chính thức.



Hình 3.6. Đường cong ROC của bốn mô hình

SVM và Random Forest có AUC xấp xỉ 0,993, nghĩa là hai mô hình xếp hạng rất tốt ảnh fire cao hơn non_fire trên nhiều ngưỡng. Chênh lệch AUC giữa hai mô hình chỉ 0,0005 và không nên được diễn giải như lợi thế lớn khi chưa có khoảng tin cậy hoặc kiểm định riêng cho AUC.

3.7. Kiểm định McNemar

Bảng 3.8. Bảng chéo và kết quả kiểm định McNemar

Thành phần	Giá trị	Ý nghĩa
SVM đúng, RF đúng	5.804	Hai mô hình cùng phân loại đúng
SVM đúng, RF sai (b)	112	Bất đồng có lợi cho SVM
SVM sai, RF đúng (c)	105	Bất đồng có lợi cho RF
SVM sai, RF sai	101	Hai mô hình cùng phân loại sai
χ^2 hiệu chỉnh liên tục	0,1659	$(112 - 105 - 1)^2 / 217$
p-value	0,6838	So sánh với $\alpha = 0,05$

Nguồn: Nhóm thực hiện, tổng hợp từ dữ liệu thực nghiệm chính thức.


Vì $p = 0,6838 \geq 0,05$, chưa đủ bằng chứng để bác bỏ giả thuyết không. Nói cách khác, trên tập TEST này, chênh lệch 7 mẫu trong số 217 trường hợp bất đồng không đủ lớn để kết luận SVM và Random Forest khác nhau có ý nghĩa thống kê về tỉ lệ lỗi. Kết quả không chứng minh hai mô hình giống hệt nhau; nó chỉ cho biết dữ liệu hiện tại chưa hỗ trợ một kết luận khác biệt.

3.8. Phân tích PCA

Bảng 3.9. Tỉ lệ phương sai được giải thích bởi PCA 2D

Thành phần	Explained variance	Diễn giải
PC1	4,15%	Thành phần có phương sai lớn nhất
PC2	1,93%	Thành phần trực giao thứ hai
Tổng PC1 + PC2	6,08%	Phần phương sai được giữ trong hình 2D
Phần còn lại	93,92%	Thông tin nằm ở các chiều khác

Nguồn: Nhóm thực hiện, tổng hợp từ dữ liệu thực nghiệm chính thức.



Hình 3.7. Phân bố dữ liệu trong không gian PCA hai chiều

Theo kết quả project, biểu đồ scatter PCA cho thấy hai lớp hình thành các vùng tương đối khác nhau. Tuy nhiên, PC1 và PC2 chỉ giữ 6,08% phương sai; vì vậy không nên dùng hình 2D để kết luận dữ liệu có thể phân tách tuyến tính hoặc để giải thích

đầy đủ hiệu năng của SVM RBF. Kết quả phân loại cao có thể dựa trên cấu trúc nằm ở nhiều chiều và ranh giới phi tuyến.

|

3.9. Khả năng tái lập thực nghiệm

Project cố định `random_state = 42` cho các mô hình có tính ngẫu nhiên, lưu feature cache và tách từng nhóm thí nghiệm thành script độc lập. Kết quả được xuất thành CSV, còn confusion matrix, ROC và PCA được lưu dưới dạng ảnh. Cách làm này hỗ trợ kiểm tra lại metric mà không cần trích xuất đặc trưng ở mỗi lần chạy.

Để tăng mức tái lập trước khi nộp, nhóm nên bổ sung phiên bản chính xác của từng thư viện bằng `requirements lock` hoặc `pip freeze`, thông tin CPU/RAM, seed của `StratifiedKFold`, hash hoặc phiên bản dataset và lệnh chạy tạo ra từng tệp kết quả. Các bước chạy chi tiết được trình bày tại Phụ lục B.

CHƯƠNG 4. PHÂN TÍCH VÀ ĐÁNH GIÁ

4.1. So sánh tổng thể các mô hình

Kết quả Hold-out và Cross-Validation cho cùng một thứ hạng tổng quát: SVM RBF và Random Forest tạo thành nhóm dẫn đầu; Logistic Regression đứng thứ ba; KNN thấp nhất. Điều này cho thấy quan hệ giữa 5.860 đặc trưng và nhãn không hoàn toàn tuyến tính, đồng thời khoảng cách Euclidean trong không gian rất cao chiều không phải lựa chọn tối ưu.

SVM cao hơn Logistic Regression 2,18 điểm phần trăm Accuracy và 2,47 điểm phần trăm F1 trên TEST. Lợi thế này phù hợp với khả năng mô hình hóa ranh giới phi tuyến của kernel RBF. So với KNN, SVM cao hơn 8,35 điểm phần trăm Accuracy và 10,34 điểm phần trăm F1. Khoảng cách lớn chủ yếu đến từ Recall của KNN chỉ 81,16%, dù Precision vẫn đạt 90,96%.

Giữa SVM và Random Forest, chênh lệch các metric tại ngưỡng mặc định đều rất nhỏ. SVM nhỉnh hơn 0,33 điểm phần trăm Precision, 0,26 điểm Specificity và 0,12 điểm F1; Random Forest nhỉnh hơn 0,07 điểm Recall. AUC của hai mô hình chỉ lệch 0,0005. Kiểm định McNemar củng cố nhận định rằng chưa có bằng chứng thống kê cho sự khác biệt tỉ lệ lỗi trên TEST.

Kết luận kỹ thuật: Nếu tiêu chí duy nhất là chất lượng dự đoán tổng thể trên tập TEST hiện tại, SVM RBF đứng đầu. Nếu xét đồng thời chất lượng và độ trễ, Random Forest có phương án đánh đổi tốt hơn.

4.2. Độ ổn định và khả năng tổng quát hóa

Accuracy Hold-out của cả bốn mô hình nằm rất gần trung bình CV, với độ lệch tuyệt đối tối đa 0,39 điểm phần trăm. Độ lệch chuẩn CV dao động 0,37–0,53 điểm phần trăm đối với Accuracy, cho thấy kết quả ít nhạy với từng phân hoạch fold. SVM và Random Forest đặc biệt ổn định về F1, chênh Hold-out/CV lần lượt chỉ 0,09 và 0,20 điểm phần trăm.

Tuy nhiên, F1 của Logistic Regression và KNN trên TEST thấp hơn CV lần lượt 0,84 và 1,42 điểm phần trăm. Tập TEST có tỉ lệ fire 43,53%, khác với TRAIN cân bằng 50/50; sự thay đổi phân bố cùng đặc điểm khó của các mẫu TEST có thể làm Recall fire giảm. Do đó, kết quả ủng hộ tính ổn định của hai mô hình dẫn đầu, nhưng

chưa đủ để khẳng định khả năng tổng quát hóa sang camera, địa điểm, mùa hoặc điều kiện thời tiết mới.

Một nguy cơ quan trọng khác là ảnh gần trùng giữa TRAIN và TEST. Nếu cùng một cảnh hoặc các khung hình liên tiếp xuất hiện ở hai tập, metric có thể cao hơn thực tế. Context chưa cung cấp kết quả kiểm tra hash/perceptual hash, vì vậy báo cáo coi đây là vấn đề cần kiểm chứng.

4.3. Vai trò bổ trợ của HOG và Color Histogram

Color Histogram đơn đạt F1 94,47%, cao hơn HOG 0,71 điểm phần trăm. Điều này cho thấy phân bố màu đỏ, cam, vàng và vùng sáng là tín hiệu mạnh trong dataset. Dù vậy, histogram màu bỏ qua vị trí và hình dạng; các cảnh hoàng hôn hoặc ánh đèn có thể tạo phân bố màu tương tự.

Khi nối HOG và Color Histogram, F1 tăng lên 96,12%. Mức tăng 2,36 điểm phần trăm so với HOG và 1,65 điểm so với Color Histogram lớn hơn chênh lệch giữa hai đặc trưng đơn. Kết quả này cho thấy hai nhóm tín hiệu bổ trợ thay vì chỉ lặp lại thông tin. HOG giúp loại bớt các vùng màu nóng không có cấu trúc biên của lửa; Color Histogram bù cho trường hợp hình dạng ngọn lửa biến đổi.

Tuy nhiên, Combined làm số chiều tăng lên 5.860 và tổng thời gian kích bản SVM tăng lên 1.083,04 giây. Nếu triển khai trên thiết bị hạn chế tài nguyên, có thể khảo sát giảm số bins HSV, PCA/feature selection hoặc chỉ giữ một phần đặc trưng HOG hiệu quả.

4.4. Đánh đổi giữa hiệu năng và chi phí tính toán

SVM cần 467,15 giây để huấn luyện và 275,63 giây để dự đoán 6.122 ảnh. Random Forest cần 50,37 giây huấn luyện và 0,27 giây dự đoán. Theo các số liệu này, Random Forest huấn luyện nhanh hơn khoảng 9,27 lần và suy luận nhanh hơn khoảng 1.021 lần. KNN có thời gian fit nhỏ nhất 1,53 giây nhưng dự đoán 17,86 giây vì phải tính khoảng cách đến mẫu huấn luyện.

Độ trễ trung bình xấp xỉ của Random Forest là 0,044 ms/ảnh nếu chia trực tiếp thời gian batch cho 6.122 ảnh; SVM khoảng 45,02 ms/ảnh. Đây chỉ là phép quy đổi từ thời gian batch trong môi trường thử nghiệm, không phải benchmark latency

end-to-end vì chưa bao gồm đọc ảnh, tiền xử lý, trích xuất đặc trưng, truyền dữ liệu và độ trễ hệ thống.

Bảng 4.1. Đánh đổi hiệu năng và chi phí tính toán giữa SVM và Random Forest

Tiêu chí	SVM RBF	Random Forest	So sánh
Accuracy	96,64%	96,52%	SVM +0,12 điểm %
Recall fire	95,80%	95,87%	RF +0,07 điểm %
F1-Score	96,12%	96,00%	SVM +0,12 điểm %
ROC-AUC	0,9929	0,9924	SVM +0,0005
Tổng lỗi TEST	206	213	SVM ít hơn 7 lỗi
Thời gian train	467,15 s	50,37 s	RF nhanh hơn $\approx 9,27\times$
Thời gian predict	275,63 s	0,27 s	RF nhanh hơn $\approx 1.021\times$
McNemar	p = 0,6838	p = 0,6838	Chưa khác biệt có ý nghĩa

Nguồn: Nhóm thực hiện, tổng hợp từ dữ liệu thực nghiệm chính thức.

4.5. Phân tích lỗi

4.5.1. False Positive – báo cháy giả

Các ảnh non_fire bị dự đoán fire chủ yếu chứa cảnh hoàng hôn hoặc bình minh đỏ thẫm, rừng lá đỏ/cam và ánh đèn cao áp ban đêm. Các bối cảnh này tạo histogram Hue/Value gần vùng lửa. Nếu vùng sáng có biên sắc hoặc kết cấu phức tạp, HOG cũng có thể không đủ để loại trừ.

4.5.2. False Negative – bỏ sót cháy

FN tập trung ở ảnh có ngọn lửa rất nhỏ và xa, khói đen/trắng che phủ phần lớn ngọn lửa, hoặc điều kiện thiếu sáng làm màu lửa nhạt. Resize về 128×128 có thể làm mất chi tiết của ngọn lửa nhỏ; GaussianBlur dù nhẹ cũng có thể giảm một phần biên yếu. Khi khói chiếm ưu thế, cả màu và hình dạng lửa đều suy giảm.

Bảng 4.2. Tổng hợp nguyên nhân các trường hợp phân loại sai

Loại	Bối cảnh	Nguyên nhân khả dĩ	Hướng xử lý
FP	Hoàng hôn/bình minh đỏ	Hue và Value gần màu lửa	Tăng mẫu hard-negative; đặc trưng không gian màu.
FP	Lá đỏ/cam mùa thu	Phân bố màu nóng trên diện rộng	Bổ sung texture/shape; kiểm tra vùng chuyển động.
FP	Đèn cao áp ban đêm	Vùng sáng mạnh, bão hòa cao	Augmentation ánh sáng; đặc trưng cục bộ.

Loại	Bối cảnh	Nguyên nhân khả dĩ	Hướng xử lý
FN	Lửa nhỏ ở xa	Mất chi tiết sau resize	Độ phân giải cao hơn; multi-scale crop.
FN	Khói che phần lớn lửa	Tín hiệu màu và biên suy yếu	Thêm đặc trưng khói; mô hình đa lớp.
FN	Ảnh thiếu sáng	Value thấp; màu lửa nhạt	Gamma/CLAHE; augmentation độ sáng.

VỊ TRÍ CHÈN ẢNH TỪ PROJECT: chọn ảnh FP/FN tiêu biểu trong reports/errors/svm/ và reports/errors/random_forest/.

Hình 4.1. Một số trường hợp False Positive và False Negative của SVM và Random Forest
Ảnh cần bổ sung từ project: chọn các ảnh False Positive và False Negative tiêu biểu trong reports/errors/svm/ và reports/errors/random_forest/.

Từ góc độ an toàn, FN thường cần được ưu tiên giảm. Một chiến lược thực tế là hạ ngưỡng cảnh báo để tăng Recall, sau đó dùng bước xác minh thứ hai hoặc yêu cầu con người kiểm tra để kiểm soát FP. Việc chọn ngưỡng phải dựa trên chi phí nghiệp vụ, không chỉ ngưỡng mặc định 0,5.

4.6. Khuyến nghị lựa chọn mô hình

Đối với báo cáo học thuật và bài toán tối đa hóa metric trên dataset hiện tại, SVM RBF là mô hình tốt nhất. Đối với triển khai cần phản hồi nhanh hoặc xử lý batch lớn, Random Forest là lựa chọn hợp lý hơn vì chất lượng gần tương đương, Recall nhỉnh hơn nhẹ và tốc độ dự đoán vượt trội.

Khuyến nghị theo bối cảnh:

- Phân tích ngoại tuyến, không nhạy độ trễ: ưu tiên SVM RBF.
- Dịch vụ API hoặc camera có yêu cầu độ trễ thấp: ưu tiên Random Forest.
- Thiết bị biên hạn chế tài nguyên: benchmark thêm Logistic Regression hoặc giảm chiều đặc trưng.
- Bối cảnh an toàn cao: hiệu chỉnh ngưỡng theo Recall/FN và dùng xác minh nhiều tầng.
- KNN không được khuyến nghị trong cấu hình hiện tại do Recall thấp và dự đoán chậm.

Khuyến nghị cuối: Chọn Random Forest làm mô hình triển khai mặc định của baseline truyền thống; giữ SVM RBF làm mô hình đối chứng chất lượng cao. Trước khi triển khai thật, cần đo latency end-to-end và validation ngoài miền.

4.7. Hạn chế và các nguy cơ đối với tính hợp lệ

Bảng 4.3. Hạn chế của nghiên cứu và hướng khắc phục

Hạn chế	Tác động	Hướng khắc phục
Nguồn dataset chưa đầy đủ	Thiếu URL, giấy phép, tiêu chí thu thập.	Bổ sung data card, license và version/hash.
Nguy cơ ảnh gần trùng	Có thể làm kết quả TEST lạc quan.	Dùng SHA-256 + perceptual hash và chia theo nguồn/cảnh.
Một tập TEST duy nhất	Chưa chứng minh khả năng ngoài miền.	Đánh giá theo camera, địa điểm, thời tiết và mùa.
Chọn siêu tham số	Chưa nêu rõ quy trình tuning độc lập.	Dùng nested CV hoặc validation set; khóa TEST.
Chưa có khoảng tin cậy TEST	Metric điểm chưa phản ánh bất định.	Bootstrap CI cho F1/Recall/AUC.
PCA 2D giữ 6,08%	Hình 2D có thể gây diễn giải quá mức.	Báo cáo thêm nhiều PC hoặc UMAP chỉ để khám phá.
Chưa hiệu chỉnh xác suất	Score chưa chắc là xác suất tin cậy.	Calibration curve, Brier score, Platt/isotonic.
Thời gian phụ thuộc phần cứng	Không thể suy rộng tuyệt đối.	Công bố CPU/RAM, số thread và benchmark end-to-end.
Không dùng dữ liệu video	Bỏ qua thông tin chuyển động/temporal.	Mở rộng optical flow hoặc xác nhận nhiều frame.

Nguồn: Nhóm thực hiện, tổng hợp từ dữ liệu thực nghiệm chính thức.

Ngoài ra, `class_weight=balanced` trong tập TRAIN cân bằng gần như không tạo khác biệt lớn. Việc báo cáo cấu hình này vẫn hữu ích, nhưng không nên coi đây là bằng chứng mô hình đã xử lý đầy đủ mọi dạng mất cân bằng. Mất cân bằng theo bối cảnh khó, điều kiện ánh sáng hoặc nguồn camera mới là các biến ẩn cần quan tâm.

4.8. Hướng cải tiến

4.8.1. Cải tiến dữ liệu

- Bổ sung hard-negative: hoàng hôn, đèn, lá đỏ, nguồn nhiệt và ánh phản xạ.
- Tăng số mẫu lửa nhỏ, bị khói che, thiếu sáng và ảnh xa.

- Kiểm tra trùng lặp và chia dữ liệu theo cảnh, video hoặc nguồn camera.
- Gắn metadata điều kiện chụp để đánh giá theo từng phân nhóm.

4.8.2. Cải tiến đặc trưng và mô hình

- Tối ưu HOG: thử cell 8×8 , multi-scale hoặc spatial pyramid.
- So sánh số bins HSV 8/16/32 và histogram theo vùng để giữ thông tin không gian.
- Bổ sung texture LBP, color moments hoặc đặc trưng khối.
- Dùng PCA/SelectKBest để giảm chiều, đặc biệt cho KNN và SVM.
- Tối ưu siêu tham số bằng nested CV; cân nhắc Linear SVM và Gradient Boosting.

4.8.3. Cải tiến đánh giá và triển khai

- Báo cáo bootstrap 95% CI cho Recall, F1 và AUC trên TEST.
- Vẽ precision-recall curve và chọn ngưỡng theo chi phí FN/FP.
- Hiệu chỉnh xác suất và theo dõi drift dữ liệu sau triển khai.
- Đo throughput, p50/p95 latency, RAM và kích thước model trên phần cứng mục tiêu.
- Thiết kế cơ chế human-in-the-loop và cảnh báo nhiều mức rủi ro.

CHƯƠNG 5. KẾT LUẬN

5.1. Kết quả đạt được

Bài tập lớn đã xây dựng quy trình phân loại ảnh cháy hoàn chỉnh bằng học máy truyền thống, từ tiền xử lý, trích xuất HOG và Color Histogram, lưu feature cache, chuẩn hóa trong pipeline, huấn luyện bốn mô hình, đánh giá Hold-out và 5-fold Cross-Validation đến phân tích AUC, McNemar, PCA và lỗi dự đoán. Quy trình sử dụng 21.731 ảnh và giữ tập TEST 6.122 ảnh độc lập cho đánh giá cuối.

SVM RBF đạt kết quả cao nhất về chất lượng dự đoán với Accuracy 96,64%, F1-Score 96,12% và AUC 0,9929. Random Forest đạt Accuracy 96,52%, F1 96,00%, Recall 95,87% và AUC 0,9924, trong khi thời gian dự đoán chỉ 0,27 giây. Kết quả cross-validation của hai mô hình ổn định, còn McNemar cho $p = 0,6838$, chưa cho thấy khác biệt có ý nghĩa thống kê.

So sánh đặc trưng xác nhận giả thuyết chính của đề tài: màu sắc là tín hiệu mạnh, nhưng việc bổ sung HOG giúp tăng rõ rệt hiệu năng. Combined đạt F1 96,12%, cao hơn Color Histogram 1,65 điểm phần trăm và HOG 2,36 điểm phần trăm.

5.2. Trả lời câu hỏi nghiên cứu

Bảng 5.1. Đối chiếu mục tiêu nghiên cứu và kết quả đạt được

Câu hỏi	Kết luận	Mức đáp ứng
RQ1	Mô hình tốt nhất về metric là SVM RBF; Random Forest bám sát.	Đạt
RQ2	Color Histogram tốt hơn HOG đơn; Combined tốt nhất.	Đạt
RQ3	Accuracy Hold-out/CV gần nhau; SVM và RF ổn định nhất.	Đạt, có giới hạn
RQ4	McNemar $p=0,6838$: chưa đủ bằng chứng SVM khác RF.	Đạt
RQ5	RF phù hợp triển khai tốc độ; SVM phù hợp ưu tiên chất lượng.	Đạt

Nguồn: Nhóm thực hiện, tổng hợp từ dữ liệu thực nghiệm chính thức.

5.3. Kết luận lựa chọn mô hình

Nếu báo cáo một mô hình có điểm số dự đoán cao nhất, lựa chọn là SVM RBF. Nếu lựa chọn một mô hình để tiếp tục phát triển thành baseline triển khai, lựa chọn phù hợp hơn là Random Forest vì chênh lệch chất lượng rất nhỏ, Recall fire cao hơn nhẹ, kiểm định chưa cho thấy khác biệt có ý nghĩa và tốc độ dự đoán vượt trội.

Logistic Regression có thể là phương án nhẹ; KNN không phù hợp trong cấu hình hiện tại.

Kết luận cuối cùng: Random Forest là phương án cân bằng tốt nhất giữa độ chính xác, khả năng phát hiện cháy và tốc độ suy luận; SVM RBF là mốc tham chiếu chất lượng cao nhất trên bộ dữ liệu hiện tại.

5.4. Hướng phát triển tiếp theo

Các bước tiếp theo nên ưu tiên chất lượng dữ liệu và đánh giá ngoài miền trước khi mở rộng mô hình. Nhóm cần bổ sung nguồn và giấy phép dataset, loại ảnh gần trùng, đánh giá theo camera/điều kiện chiếu sáng, thiết lập validation cho tuning, tính khoảng tin cậy và tối ưu ngưỡng theo chi phí FN. Sau khi baseline được củng cố, có thể so sánh với CNN nhẹ hoặc mô hình chuyển giao, nhưng vẫn giữ quy trình hiện tại làm đối chứng để giải thích.

TÀI LIỆU THAM KHẢO

- [1] J. Han, M. Kamber, and J. Pei, Data Mining: Concepts and Techniques, 3rd ed. Waltham, MA: Morgan Kaufmann, 2012.
- [2] N. Dalal and B. Triggs, “Histograms of Oriented Gradients for Human Detection,” in Proc. IEEE CVPR, vol. 1, pp. 886–893, 2005. DOI: 10.1109/CVPR.2005.177. <https://doi.org/10.1109/CVPR.2005.177>
- [3] C. Cortes and V. Vapnik, “Support-vector networks,” Machine Learning, vol. 20, pp. 273–297, 1995. DOI: 10.1007/BF00994018. <https://doi.org/10.1007/BF00994018>
- [4] T. M. Cover and P. E. Hart, “Nearest neighbor pattern classification,” IEEE Transactions on Information Theory, vol. 13, no. 1, pp. 21–27, 1967. DOI: 10.1109/TIT.1967.1053964. <https://doi.org/10.1109/TIT.1967.1053964>
- [5] L. Breiman, “Random Forests,” Machine Learning, vol. 45, pp. 5–32, 2001. DOI: 10.1023/A:1010933404324. <https://doi.org/10.1023/A:1010933404324>
- [6] F. Pedregosa et al., “Scikit-learn: Machine Learning in Python,” Journal of Machine Learning Research, vol. 12, pp. 2825–2830, 2011. <https://jmlr.org/papers/v12/pedregosa11a.html>
- [7] scikit-image, “Histogram of Oriented Gradients,” documentation, accessed 11 Aug. 2026. https://scikit-image.org/docs/stable/auto_examples/features_detection/plot_hog.html
- [8] OpenCV, “Color Space Conversions,” documentation, accessed 11 Aug. 2026. https://docs.opencv.org/3.4.20/d8/d01/group_imgproc_color_conversions.html
- [9] scikit-learn, “Cross-validation: evaluating estimator performance,” documentation, accessed 11 Aug. 2026. https://scikit-learn.org/stable/modules/cross_validation.html
- [10] T. Fawcett, “An introduction to ROC analysis,” Pattern Recognition Letters, vol. 27, no. 8, pp. 861–874, 2006. DOI: 10.1016/j.patrec.2005.10.010. <https://doi.org/10.1016/j.patrec.2005.10.010>
- [11] Q. McNemar, “Note on the sampling error of the difference between correlated proportions or percentages,” Psychometrika, vol. 12, pp. 153–157, 1947. DOI: 10.1007/BF02295996. <https://doi.org/10.1007/BF02295996>
- [12] I. T. Jolliffe and J. Cadima, “Principal component analysis: a review and recent developments,” Philosophical Transactions of the Royal Society A, vol. 374, art. 20150202, 2016. DOI: 10.1098/rsta.2015.0202. <https://doi.org/10.1098/rsta.2015.0202>
- [13] scikit-learn, “Pipeline,” API documentation, accessed 11 Aug. 2026. <https://scikit-learn.org/stable/modules/generated/sklearn.pipeline.Pipeline.html>
- [14] Nhóm thực hiện, “Context kỹ thuật và số liệu thực nghiệm chính thức của BTL Khai phá dữ liệu,” tài liệu nội bộ kèm project, tháng 8/2026.
- [15] D. Tester, “Phân loại hình ảnh cháy dựa trên đặc trưng HOG và Color Histogram,” GitHub repository, truy cập ngày 11/08/2026. https://github.com/ddung-tester/Phan_loai_chay_datamining

Cần hoàn thiện trước khi nộp: Bổ sung trích dẫn đầy đủ cho Forest Fire & Non-Fire Dataset (tác giả/đơn vị, URL, phiên bản, ngày truy cập và giấy phép) sau khi nhóm xác nhận nguồn dữ liệu gốc.

PHỤ LỤC A. CẤU TRÚC PROJECT VÀ TẬP KẾT QUẢ

Bảng A.1. Cấu trúc thư mục chính của project

Đường dẫn	Nội dung
data/raw/train	Ảnh gốc TRAIN, gồm fire/ và non_fire/.
data/raw/test	Ảnh gốc TEST độc lập, gồm fire/ và non_fire/.
data/processed/train	X_hog.npy, X_color.npy, X_combined.npy và y.npy của TRAIN.
data/processed/test	Feature cache tương ứng của TEST.
models/official	Các model đã huấn luyện; một số model lớn không push repository.
reports/figures	ROC, PCA, confusion matrix và biểu đồ so sánh.
reports/results	Các tệp CSV kết quả chính thức.
reports/errors	Ảnh False Positive và False Negative theo mô hình.
src	Mã nguồn tiền xử lý, trích đặc trưng, huấn luyện và đánh giá.

Nguồn: README.md của project trên GitHub [15].

Bảng A.2. Danh sách tệp kết quả chính thức

Tệp	Nội dung
model_comparison_OFFICIAL.csv	Hold-out: metrics, confusion counts, AUC và thời gian bốn mô hình.
cross_validation_OFFICIAL.csv	Mean $\pm$ Std của 5-fold CV.
feature_comparison_OFFICIAL.csv	So sánh HOG, Color Histogram và Combined.
final_summary_OFFICIAL.csv	Tổng hợp Hold-out và CV.
roc_auc_OFFICIAL.csv	ROC-AUC bốn mô hình.
mcnemar_svm_vs_rf_OFFICIAL.csv	Bảng chéo và kết quả kiểm định.
pca_summary_OFFICIAL.csv	Explained variance của PCA.
roc_curve_OFFICIAL.png	Đường cong ROC gốc.
pca_feature_space_OFFICIAL.png	Scatter PCA 2D gốc.
cm_*_OFFICIAL.png	Confusion matrix từng mô hình.

Nguồn: Nhóm thực hiện, tổng hợp từ dữ liệu thực nghiệm chính thức.

Kích thước model được mô tả trong context: SVM khoảng 240 MB, KNN khoảng 349 MB, Random Forest khoảng 18 MB; hai model lớn không được push. Các con số này nên được đo lại trực tiếp từ artifact trước khi đưa vào tài liệu triển khai chính thức.

PHỤ LỤC B. HƯỚNG DẪN CHẠY LẠI THỰC NGHIỆM

B.1. Cài đặt môi trường

```
python -m venv .venv
.venv\Scripts\activate
pip install -r requirements.txt
```

Yêu cầu Python 3.10 trở lên. Trên Linux/macOS, lệnh kích hoạt môi trường ảo là `source .venv/bin/activate`.

Bảng B.1. Trình tự chạy lại các bước thực nghiệm

Bước	Lệnh	Kết quả
1	<code>python -m src.feature_cache</code>	Xây dựng feature cache; cần ảnh gốc.
2	<code>python -m src.train_compare</code>	Huấn luyện và đánh giá Hold-out bốn mô hình.
3	<code>python -m src.train_cv_official</code>	Chạy 5-Fold Stratified CV.
4	<code>python -m src.feature_compare_official</code>	So sánh ba bộ đặc trưng bằng SVM.
5	<code>python -m src.final_evaluation_official</code>	Confusion matrix và error analysis.
6	<code>python -m src.advanced_analysis_official</code>	ROC-AUC, PCA và McNemar.

Lưu ý: Bước 1 cần có `data/raw/train` và `data/raw/test`. Từ bước 2 đến bước 6 có thể dùng feature cache đã tạo. Không chỉnh sửa hoặc xem nhãn TEST trong quá trình lựa chọn siêu tham số.

PHỤ LỤC C. MÃ GIẢ QUY TRÌNH XỬ LÝ

C.1. Tiền xử lý và trích xuất đặc trưng

```
INPUT: image
1. image_resized ← resize(image, 128 × 128, INTER_AREA)
2. image_smooth  ← GaussianBlur(image_resized, kernel = 3 × 3)
3. gray          ← convert_to_grayscale(image_smooth)
4. hog_vector    ← HOG(gray, orientations=9,
                        pixels_per_cell=16 × 16,
                        cells_per_block=2 × 2,
                        block_norm=L2-Hys)
5. hsv          ← BGR_to_HSV(image_smooth)
6. color_vector  ← histogram_3D(hsv, bins=16 × 16 × 16)
7. color_vector  ← normalize(color_vector)
8. combined     ← concatenate(hog_vector, color_vector)
OUTPUT: hog_vector[1764], color_vector[4096], combined[5860]
```

C.2. Huấn luyện và đánh giá Hold-out

```
INPUT: X_train, y_train, X_test, y_test
FOR each classifier in {LR, KNN, SVM_RBF, RandomForest}:
    pipeline ← Pipeline(StandardScaler(), classifier)
    pipeline.fit(X_train, y_train)
    y_pred   ← pipeline.predict(X_test)
    y_score  ← decision_function or predict_proba
    calculate Accuracy, Precision, Recall, F1, Specificity, ROC-AUC
    save confusion matrix, execution time and trained model
END FOR
```

C.3. Cross-Validation đúng cách

```
cv ← StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
FOR each fold (train_idx, val_idx):
    scaler.fit(X_train[train_idx])          # chỉ fit trên train fold
    X_fold_train ← scaler.transform(...)
    X_fold_val   ← scaler.transform(...)
    model.fit(X_fold_train, y_train[train_idx])
    evaluate(model, X_fold_val, y_train[val_idx])
REPORT mean ± standard deviation across five folds
```

PHỤ LỤC D. KIỂM TRA TÍNH NHẤT QUÁN SỐ LIỆU

Các chỉ số Hold-out được tính lại từ TP, TN, FP và FN để kiểm tra sai lệch sao chép. Kết quả dưới đây khớp với số liệu công bố sau khi làm tròn hai chữ số thập phân.

Bảng D.1. Đối soát chỉ số từ ma trận nhầm lẫn

Mô hình	N	Acc.	Prec.	Recall	F1	Spec.	KQ
Logistic Regression	6.122	94,46%	93,49%	93,81%	93,65%	94,97%	Khớp
KNN (k=5)	6.122	88,29%	90,96%	81,16%	85,78%	93,78%	Khớp
SVM (RBF)	6.122	96,64%	96,45%	95,80%	96,12%	97,28%	Khớp
Random Forest	6.122	96,52%	96,12%	95,87%	96,00%	97,02%	Khớp

Nguồn: Nhóm thực hiện tính lại từ confusion matrix chính thức.

Tổng mẫu của mỗi mô hình đều bằng 6.122. Với SVM: $TP + TN = 5.916$, nên $Accuracy = 5.916 / 6.122 = 96,64\%$; $Precision = 2.553 / (2.553 + 94) = 96,45\%$; $Recall = 2.553 / 2.665 = 95,80\%$; $Specificity = 3.363 / 3.457 = 97,28\%$. Các mô hình còn lại được kiểm tra tương tự.

Kết quả kiểm tra: Không phát hiện mâu thuẫn giữa confusion matrix và các metric Hold-out. Ma trận McNemar cũng nhất quán: $5.804 + 112 + 105 + 101 = 6.122$; số mẫu SVM đúng $= 5.804 + 112 = 5.916$ và RF đúng $= 5.804 + 105 = 5.909$.